НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ «ОДЕСЬКА ПОЛІТЕХНІКА»
МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ІНСТИТУТ КОМП'ЮТЕРНИХ СИСТЕМ
КАФЕДРА ІНФОРМАЦІЙНИХ СИСТЕМ

Протокол лабораторної роботи №1

«Розгортання середовища та порівняльний аналіз мовних моделей»

з дисципліни: «Обчислювальні методи»

Виконав:
студент групи AI-243
Іпатов Богдан Сергійович
Варіант 11 (Тема: «Освіта»)

Перевірив:
ас. Баранов О.М.

Одеса – 2026

ЗАВДАННЯ 1. ЦІНА РОЗДУМІВ: МІРКУВАЛЬНА VS ІНСТРУКТИВНА МОДЕЛЬ

Мета завдання: на практиці порівняти поведінку та накладні витрати двох різних локальних мовних моделей: інструктивної (`llama3.2:3b`) та міркувальної (`qwen3:4b`). Запити надсилалися напряму до локального сервісу Ollama через REST API (`/api/generate`). Перед основними вимірами виконувався прогрівальний запит.

Таблиця 1 – Фактичне питання «Столиця України? Відповідай одним словом.»

Показник	qwen3:4b (міркувальна)	llama3.2:3b (інструктивна)
`response`	Киев	Київ.
`eval_count` (токенів)	2759	5
Час, с	25.05	0.05
Токенів/с	110.44	160.11

Таблиця 2 – Задача на міркування (середнє з 5 запусків)

Показник	qwen3:4b (міркувальна)	llama3.2:3b (інструктивна)
Правильних із 5	**5 / 5 (100%)**	2 / 5 (помилка 10 грн)
`eval_count` (середнє)	1353.2	215.0
Час, с (середнє)	12.03	1.57

Аналіз помилки інструктивної моделі: *у трьох спробах із 5 модель llama3.2 видала інтуїтивну відповідь «10 грн». Вона просто відняла 100 від 110, не врахувавши, що різниця в 100 грн ділиться навпіл: зошит коштує x, ручка x + 100 грн, разом: x + (x + 100) = 110 → 2x = 10 → x = 5 грн.*

Відповіді на питання (крок 6):

1. Куди пішли додаткові токени в міркувальної моделі?

Усі додаткові токени (у qwen3:4b їх аж 2759 проти всього 5 у llama3.2) пішли на генерацію внутрішнього блоку роздумів. Модель подумки перебирала історичні факти про Київ, перевіряла географічний статус міста і кілька разів перепитувала сама себе, перш ніж вивести одне фінальне слово.

2. На яких типах задач міркувальні моделі дають перевагу, а на яких їх використання невиправдане?

Міркувальні моделі дають реальну перевагу там, де потрібно подумати в кілька послідовних кроків: у математиці, алгоритмах, написанні коду та логічних тестах. А для простих фактичних запитань або швидкого переказу тексту вони абсолютно

невиправдані, бо змушують чекати у сотні разів довше без жодного виграшу в точності.

3. Чим відрізняється процес навчання міркувальної моделі від інструктивної?

Звичайні інструктивні моделі навчають одразу видавати готову відповідь за шаблонами запитань. Міркувальні моделі додатково тренують за допомогою навчання з підкріпленням (Reasoning RL), заохочуючи модель будувати логічний ланцюжок думок, шукати альтернативи та самостійно перевіряти проміжні результати.

4. Чи означає більша кількість токенів, що модель «розумніша»?

Ні, кількість токенів показує лише те, наскільки багато тексту модель згенерувала всередині. Якщо в задачі дійсно потрібна логіка, ці токени допомагають знайти правильний розв'язок. Але на тривіальних фактах довгі міркування — це просто зайва трата ресурсів і часу.

5. Як пояснити різницю у швидкості генерації (токенів за секунду)?

Модель llama3.2 працює швидше (~160 токенів/с проти ~110 у qwen3), тому що вона компактніша (3 мільярди параметрів проти 4 мільярдів) і моїй відеокарті легше прораховувати кожен наступний токен.

Висновок за завданням 1

Головний висновок цього досліду — не слід плутати швидкість роботи відеокарти (токенів за секунду) із загальним часом очікування відповіді. llama3.2 виводить токени швидше, але на логічній задачі помилилася у більшості випадків. Міркувальна модель qwen3 хоч і думає по 12 секунд, зате видала 100% правильних відповідей. Отже, вибір моделі має залежати від типу задачі: для швидких відповідей підійде звичайна інструктивна модель, а для математики й логіки — міркувальна.

ЗАВДАННЯ 2. РОЛЬ SYSTEM-ПОВІДОМЛЕННЯ: КЕРУВАННЯ ПОВЕДІНКОЮ МОДЕЛІ

Питання варіанта: «Поясни різницю між списком і кортежем у Python.»

Я протестував обидві моделі з двома різними системними підказками: лаконічний асистент та суворе обмеження (українською мовою, максимум 2 речення).

Таблиця 3 – Вплив system-повідомлення на вихідний текст

Модель	System-повідомлення	Довжина	Мова	Речень	Виконано?
llama3.2:3b	лаконічний асистент	1323	укр. (суржик, нідерл.)	17	Ні (17 речень)
llama3.2:3b	українською, 2 речення	246	укр. (полонізм «różниця»)	2	Частково
qwen3:4b	лаконічний асистент	131	літературна українська	2	**Так (ідеально)**
qwen3:4b	українською, 2 речення	184	літературна українська	2	**Так (ідеально)**

Таблиця 4 – Витрати токенів при зміні system-повідомлення

Модель	System-повідомлення	prompt_tokens	completion_tokens	total_tokens
llama3.2:3b	лаконічний асистент	54	437	491
llama3.2:3b	українською, 2 речення	58	76	134
qwen3:4b	лаконічний асистент	55	1903	1958
qwen3:4b	українською, 2 речення	64	824	888

Відповіді на питання (крок 6):

1. Яка модель точніше дотрималась обмеження «максимум двома реченнями»?

Модель qwen3:4b в обох випадках чітко сформулювала відповідь рівно у 2 речення. llama3.2:3b при першому запиті повністю проігнорувала вимогу бути лаконічною і згенерувала довжелезний текст на 17 речень (1323 символи).

2. Чи були випадки, коли модель відповіла не українською?

Так, у відповідях llama3.2:3b постійно траплялися мовні артефакти: суржик («обрбота», «сквіток»), нідерландське слово «kunnen» («Lists kunnen змінюватися») та польська літера «ó» у слові «różниця». У qwen3:4b мова була чистою українською.

3. Як змінився prompt_tokens при зміні system-повідомлення?

Кількість токенів у запиті трохи зросла (з 54 до 58 у llama і з 55 до 64 у qwen), оскільки друга системна інструкція довша за текстом.

4. Чому в qwen3:4b значення completion_tokens значно більше?

Тому що в загальну кількість токенів генерації API додає всі внутрішні токени блоку думок, хоча у фінальну відповідь користувачу виводиться лише короткий результат.

Висновок за завданням 2

Системний промпт допомагає задати поведінку моделі, але сам по собі не дає стовідсоткової гарантії, особливо для невеликих моделей. Якщо в реальному проекті обов'язково потрібен суворий формат і довжина, краще використовувати структурний вивід (JSON mode) та перевірку кодом.

ЗАВДАННЯ 3. ЛОКАЛЬНА VS ХМАРНА МОДЕЛЬ: ЄДИНИЙ ІНТЕРФЕЙС

Питання варіанта: «Поясни різницю між списком і кортежем у Python. Коротко.»

Я підключив хмарну модель через Groq API за тим самим інтерфейсом бібліотеки OpenAI, що й локальну Ollama. Для перемикання між локальною моделлю та хмарою достатньо просто змінити екземпляр клієнта у `providers.py`, не змінюючи жодного рядка логіки в скрипті `compare.py`.

Таблиця 5 – Порівняння локальної та хмарної моделі

Показник	Локальна (llama3.2:3b)	Хмарна (qwen/qwen3.8-27b на Groq)
Назва моделі	`llama3.2:3b`	`qwen/qwen3.8-27b`
Час відповіді, с	3.59 с	**0.96 с**
`completion_tokens`	172	245
Довжина відповіді, симв.	570	790
Мова відповіді	укр. (суржик, «обрбота», «невибачливі»)	**бездоганна українська мова**
Фактичні помилки	Так («списки сидять на диску»)	**Немає (точні терміни, мутабельність)**

Відповіді на питання (крок 5):

1. Скільки рядків коду довелося змінити?

У самій програмі compare.py я не змінював жодного рядка. Усі налаштування (адреса сервера, ключ та назва моделі) ізольовані у модулі providers.py.

2. Яка відповідь повніша й точніша?

Відповідь хмарної моделі значно якісніша: вона грамотно пояснила змінюваність, синтаксис та ефективність використання пам'яті. Локальна модель помилилася і написала абсурдну річ, ніби списки у Python зберігаються на диску.

3. Хмарна модель відповіла швидше за рахунок чого?

Вона відповіла швидше менш ніж за 1 секунду завдяки спеціалізованим процесорам Groq LPU (Language Processing Units), які спеціально оптимізовані під швидкий інференс великих моделей.

Висновок за завданням 3

Єдиний стандарт OpenAI API дозволяє легко будувати гнучку архітектуру. Локальна модель повністю конфіденційна, безкоштовна і працює без підключення до мережі, але її якість обмежена розміром. Хмарна модель на 27 мільярдів параметрів дає набагато глибшу та грамотнішу відповідь і працює швидше за рахунок серверних потужностей.

ЗАВДАННЯ 4. ВИМІРЮВАННЯ ШВИДКОСТІ: TTFT І ЗАЛЕЖНІСТЬ ВІД ДОВЖИНИ ЗАПИТУ

Для оцінки продуктивності я використав три типи запитів різної складності (короткий, середній, довгий).

Таблиця 6 – Результати вимірювання швидкості інференсу

Провайдер	Модель	Запит	TTFT, с	Загальний час, с	Символів/с
local	llama3.2:3b	короткий	2.068	2.270	14.3
local	llama3.2:3b	середній	2.083	2.911	101.0
local	llama3.2:3b	довгий	2.087	6.745	365.9
local2	qwen3:4b	короткий	5.646	5.672	5.3
local2	qwen3:4b	середній	21.126	21.941	18.4
local2	qwen3:4b	довгий	40.547	46.178	20.9
cloud	qwen/qwen3.8-27b	короткий	**0.164**	**0.184**	152.4
cloud	qwen/qwen3.8-27b	середній	**1.051**	**1.263**	284.2
cloud	qwen/qwen3.8-27b	довгий	**0.267**	**2.458**	**1201.4**

Таблиця 7 – Холодний і теплий старт локальної моделі llama3.2:3b

Показник	Холодний старт (`ollama stop`)	Теплий старт (у пам'яті VRAM)
TTFT, с	3.500 с	2.057 с
Загальний час, с	4.003 с	2.150 с

8

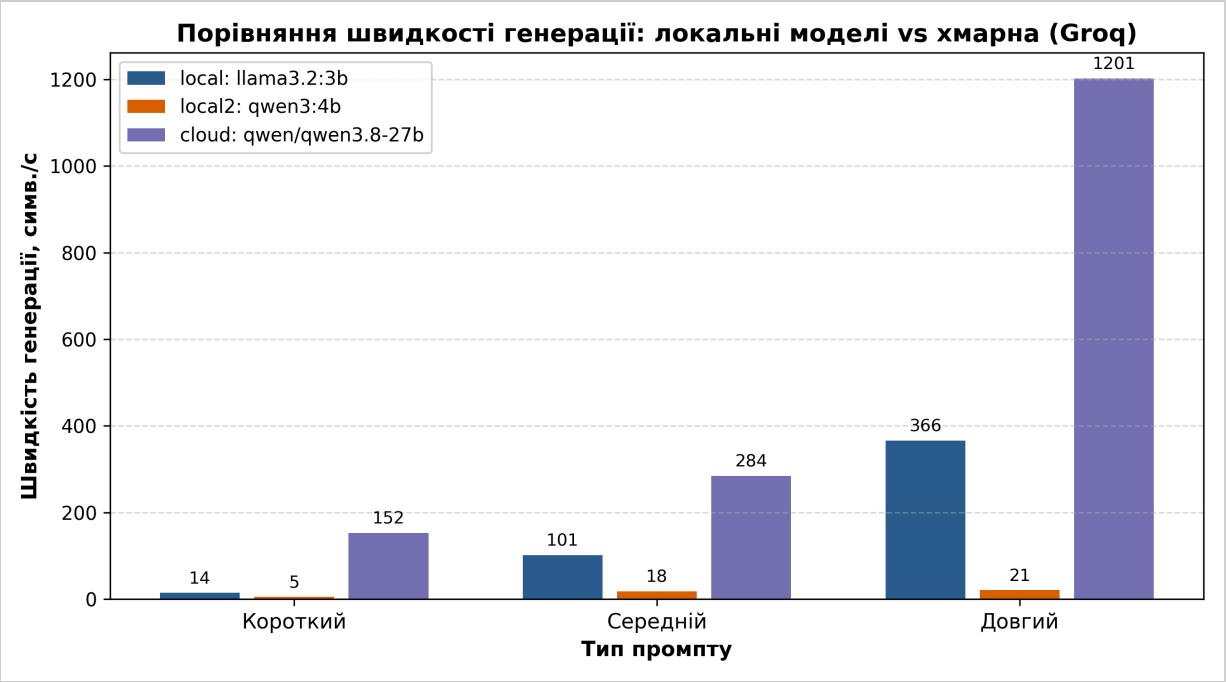


Рисунок 1 – Порівняння швидкості генерації (символів/с) та TTFT (с)

Висновок за завданням 4

Для інтерактивного спілкування користувача з моделлю найважливішим є показник TTFT (час до появи першого символу). Хмарний сервіс Groq забезпечує мінімальну затримку (0.16–0.26 с), а швидкість видачі тексту досягає понад 1200 символів на секунду. Локальна модель тримає стабільний TTFT близько двох секунд. При холодному старті додається ще приблизно 1.5 секунди на зчитування моделі з диска в пам'ять відеокарти.

ЗАВДАННЯ 5. ОЦІНЮВАННЯ ЯКОСТІ МОДЕЛЕЙ ЗА РУБРИКОЮ

Тема варіанта: «Освіта». Я оцінив три моделі за 6 критеріями (максимум 2 бали за кожен, усього 12 балів).

Таблиця 8 – Оцінка якості за рубрикою (максимум 12 балів)

Критерій оцінювання	llama3.2:3b	qwen3:4b	Хмарна (qwen/qwen3.8-27b)
1. Фактична точність (ОНУ: 1865 рік)	0	0	2
2. Дотримання формату (чистий JSON)	2	2	2
3. Стиснення зі збереженням 7 чисел	0	2	2
4. Написання коду (is_palindrome)	2	2	2
5. Логічна задача (25 студентів)	0	2	2
6. Українська мова (стек vs черга)	1	2	2
Загальний бал із 12	**5 / 12**	**10 / 12**	**12 / 12**

Таблиця 9 – Стабільність оцінок між двома запусками

Критерій	llama3.2:3b	qwen3:4b	Хмарна модель
1. Фактична точність	Є розбіжність (1828 vs 1908)	Стабільно (1917 в обох)	Стабільно (1865 в обох)
2. Дотримання формату	Стабільно	Стабільно	Стабільно
3. Стиснення з числами	Є розбіжність (губить числа)	Стабільно	Стабільно
4. Написання коду	Розбіжність у markdown	Стабільно	Стабільно
5. Логічна задача	Розбіжність (помилка vs цикл)	Стабільно	Стабільно
6. Українська мова	Стабільно суржик	Стабільно	Стабільно

Аналіз показового збою (крок 7):

Умова задачі: «25 студентів, 12 знають Python, 9 Java, 4 знають обидві мови. Скільки студентів не знають жодної мови? Покажи хід розв'язання.»

Поведінка llama3.2:3b у другому прогоні: модель зациклилася і 5 разів поспіль повторила речення *«Поняття 'не знають жодної мови' не означає, що студент не знає жодної мови...»*, після чого несподівано вивела китайські ієрогліфи *«нам нужно計算»*.

Правильний розв'язок:

Знають хоча б одну мову: 12 + 9 - 4 = 17 студентів.

Не знають жодної мови: 25 - 17 = 8 студентів.

Причина збою: малій моделі без спеціального блоку роздумів не вистачило уваги для багатокрокового міркування, через що виникло зациклення та розпад тексту на інші мови.

Висновок за завданням 5

Рубрика чітко показує межі можливостей кожної моделі. Мала модель 3B підходить лише для найпростіших завдань і короткого коду. Модель 4B з блоком міркувань відмінно справляється з логікою і текстом, але плутає локальні історичні дати. Хмарна модель 27B показала максимальний результат 12 з 12 балів.

ЗАВДАННЯ 6. КЕРУВАННЯ ВИПАДКОВІСТЮ: TEMPERATURE І TOP_P

Завдання варіанта:

• Творче: «Придумай назву стартапу в галузі логістики»

• Фактичне: «Вкажи рік заснування Національного університету 'Одеська Політехніка'» (правильна відповідь: 1918)

Таблиця 10 – Вплив параметрів на різноманітність та точність відповідей

Параметр	Значення	Унікальних із 5 (творче)	Правильних із 5 (фактичне)
`temperature`	0.0	1	0 / 5 (стабільно 1925)
`temperature`	0.7	5	—
`temperature`	1.5	5	0 / 5 (1993, 1928, 1964 та дивні слова)
`top_p`	0.1	1	—
`top_p`	0.5	4	—
`top_p`	1.0	5	—

Таблиця 11 – Перевірка повторюваності при temperature = 0.0

Показник	Отримане значення
Кількість контрольних запусків	10
Значення `temperature`	0.0
Кількість унікальних відповідей	1
Усі відповіді повністю ідентичні	**Так (10 з 10)**

Висновок за завданням 6

Параметр temperature безпосередньо регулює випадковість вибору наступних токенів. Для завдань, де потрібна передбачуваність або строгий формат даних, слід фіксувати temperature = 0.0. Для креативних задач гарні результати дає значення 0.7. А при завищеній температурі (1.5) починається деградація мови: модель плутає слова і вигадує випадкові дати. Також важливо пам'ятати, що нульова температура не робить модель розумнішою: якщо модель не знає факт, вона просто 10 разів впевнено повторить одну й ту саму помилку.

ЗАВДАННЯ 7. ПІДСУМКОВЕ ПОРІВНЯННЯ ТА ЗАГАЛЬНИЙ ВИСНОВОК

Таблиця 12 – Порівняльна характеристика протестованих моделей

Критерій	Локальна мала (3B)	Локальна міркувальна (4B)	Хмарна (27B на Groq)
Швидкість генерації	14–365 симв./с	5–21 симв./с	**152–1201 симв./с (Groq LPU)**
Час до першого токена (TTFT)	2.05–2.08 с	5.6–40.5 с	**0.16–0.26 с**
Загальна якість (рубрика)	5 / 12	10 / 12	**12 / 12**
Стабільність форматування	Середня	Висока	Висока
Необхідні ресурси	2 ГБ VRAM, 8 ГБ RAM	3.5 ГБ VRAM, 16 ГБ RAM	Лише доступ до інтернету
Вартість використання	Безкоштовно (на ПК)	Безкоштовно (на ПК)	Free tier / за токени
Конфіденційність даних	Залишаються на ПК	Залишаються на ПК	Передаються на сервери Groq
Робота без інтернету	**Так**	**Так**	Ні
Рекомендована сфера	Базові скрипти, автономність	Логіка й розрахунки офлайн	Промислові агенти, аналітика

Загальні висновки:

1. Єдиний інтерфейс OpenAI: Використання стандартизованого API дозволяє легко перемикатися між локальними моделями в Ollama та хмарними сервісами через конфігурацію, не змінюючи код самої програми.

2. Розділення затримок: Загальний час очікування відповіді складається з двох різних речей: затримки до першого токена (TTFT) та швидкості генерації тексту. Оцінювати модель за одним загальним часом некоректно.

3. Область застосування міркувань: Ланцюжок думок (Chain of Thought) незамінний для логічних і математичних задач, але для простих фактів або переказу він лише створює надлишкове навантаження і затримку.

4. Керування форматом: Текстові підказки в системному промпті не гарантують суворого дотримання формату для малих моделей. У надійних додатках потрібна перевірка кодом та використання JSON mode.

5. Вплив стохастичності: При temperature = 0.0 результат стає повністю повторюваним, проте не гарантує фактичної правдивості. Будь-які експерименти з

моделями слід проводити серіями з кількох вимірювань для усунення випадкових викидів.